

天猫用户重复购买预测项目报告

一、项目背景

随着电商平台竞争日益激烈，新用户获取成本持续上升，而大量用户在首次购买后不再复购，导致营销投入难以形成长期价值。

因此，如何识别高复购潜力用户、提升用户生命周期价值（LTV）、提高营销 ROI，成为电商平台精准营销的重要研究方向。

本项目基于天猫真实脱敏用户行为数据，结合用户点击、收藏、加购、购买等行为信息，构建用户复购预测模型，对用户未来是否会再次购买进行二分类预测，为商家精准营销、用户运营及投放优化提供数据支持。

二、项目目标

本项目主要完成以下任务：

基于用户行为日志与用户画像构建用户复购预测模型；挖掘影响用户复购行为的关键因素；输出用户复购概率，实现用户价值分层；使用 AUC 指标评估模型预测效果；为精准营销与用户运营提供业务参考。

三、数据集说明

项目采用天猫真实脱敏电商数据集，包含用户、商家及行为日志等多维数据。

1. 数据文件

数据文件	数据说明
train_format1.csv	训练集（用户-商家-标签）
test_format1.csv	测试集（待预测样本）
user_info_format1.csv	用户画像信息（年龄、性别）
user_log_format1.csv	用户行为日志数据

2. 用户行为类型

行为日志包含四类核心行为：

点击（Click）

收藏（Favorite）

加购（Cart）

购买（Purchase）

整体数据规模超过千万级行为记录，属于典型电商稀疏行为数据场景。

四、数据探索与预处理

1. 数据读取与字段分析

使用 Pandas 对训练集、测试集、用户画像及行为日志进行读取与整合，并对字段类型、缺失情况及数据规模进行统计分析。

2. 缺失值处理

由于部分用户缺失年龄与性别信息，因此：年龄缺失统一填充为 0；性别缺失统一填充为 2（未知类别）。对于不存在行为记录的用户，将行为统计特征统一填充为 0，避免模型训练阶段出现空值问题。

3. 样本不平衡分析

项目数据存在明显类别不平衡问题：非复购用户占绝大多数，复购用户占比较低。因此项目未采用 Accuracy 作为核心指标，而选择更适合不平衡场景的 AUC（ROC 曲线下面积）作为模型评估标准。

五、特征工程（核心部分）

特征工程是本项目模型效果提升的关键部分。

1. 用户-商家交互行为特征

基于用户行为日志，统计用户对商家的行为强度：

特征	含义
click_cnt	点击次数
cart_cnt	加购次数
fav_cnt	收藏次数
buy_cnt	购买次数
total_behavior	总行为次数

该类特征能够反映用户对商家的兴趣程度与活跃度。

2. 行为转化率特征

为了增强模型对用户购买意图的识别能力，进一步构建：

点击转购买率（click2buy）

收藏转购买率（fav2buy）

加购转购买率（cart2buy）

购买行为占比（buy_rate）

该类特征能够有效反映用户从浏览到成交的转化能力，对模型效果提升明显。

3. 行为占比特征

为了进一步刻画用户行为结构，新增：

点击占比 (click_ratio)

加购占比 (cart_ratio)

收藏占比 (fav_ratio)

相比单纯行为次数特征，行为占比特征能够更准确反映用户兴趣偏好与消费倾向。

4. 用户全局行为特征

从用户整体行为角度构建统计特征：

用户活跃天数 (u_active_days)

用户行为种类数 (u_action_types)

用于刻画用户整体消费习惯与平台活跃水平。

5. 商家统计特征

针对商家维度构建聚合特征：

商家成交总次数 (m_buy_cnt)

商家覆盖用户数 (m_user_cnt)

商家转化率 (merchant_buy_rate)

用于反映商家吸引力与运营能力。

6. 用户画像特征

结合用户基础属性：

年龄区间 (age_range)

性别 (gender)

增强模型对不同用户群体消费偏好的识别能力。

六、模型构建

1. 模型选择

本项目采用 XGBoost 二分类模型进行预测。

选择原因包括：对表格数据表现优异，能自动学习特征交互关系，对缺失值与异常值鲁棒性较强，在工业界推荐系统与风控场景广泛应用。

2. 数据集划分

采用训练集与验证集 8:2 划分方式，并使用分层抽样（Stratified Split）保持标签分布一致。

3. 模型参数优化

为提升模型泛化能力，本项目增加：

L1 正则化（reg_alpha）

L2 正则化（reg_lambda）

节点分裂惩罚项（gamma）

同时优化：

max_depth

learning_rate

min_child_weight

等核心参数，降低模型过拟合风险。

最终模型参数如下：

n_estimators=450

max_depth=5
learning_rate=0.05
subsample=0.8
colsample_bytree=0.8
min_child_weight=5
gamma=0.1
reg_alpha=0.1
reg_lambda=1

七、模型评估

项目采用 AUC 作为核心评估指标：AUC = 0.5：随机预测；AUC > 0.6：模型具备有效预测能力；AUC > 0.65：具备较强业务应用价值。

最终模型验证集结果如下：

指标	数值
Validation AUC	0.6532

结果表明：模型能够较好地地区分高复购用户与低复购用户，具备一定业务应用价值。

八、模型优化过程

为了进一步提升模型效果，本项目进行了多轮优化。

1. 删除冗余特征

初始模型中，部分商家统计特征存在较强相关性，导致用户行为特征重要性被压制。

因此删除部分冗余特征，仅保留：商家覆盖用户数、商家购买次数、商家转化率，从而降低特征共线性，提高模型稳定性。

2. 增强行为结构特征

新增行为占比与行为转化率特征，使模型能够学习用户行为结构，而不仅是行为规模。

实验结果表明：行为结构特征对模型效果提升明显。

3. 增强模型正则化

通过增加：reg_alpha、reg_lambda、gamma，提高模型泛化能力，降低过拟合风险。

九、特征重要性分析

通过 XGBoost 特征重要性分析发现：
影响用户复购行为最重要的特征包括：

特征	含义
merchant_buy_rate	商家转化率
m_buy_cnt	商家成交次数
m_user_cnt	商家覆盖用户数
cart2buy	加购转购买率
active_days	用户活跃天数

分析表明：

- （1）商家运营能力影响显著
高转化、高成交商家更容易形成用户复购行为。
- （2）用户活跃度具有较强预测能力
高活跃用户通常具有更高复购概率。
- （3）行为转化率特征效果突出

用户从“兴趣”到“下单”的行为转化过程，是预测复购的重要依据。

十、模型可视化分析

本项目进一步绘制：ROC 曲线、特征重要性图、用户行为漏斗图、用户画像分析图，用于增强模型可解释性。

1. 用户行为漏斗分析



统计结果如下：


行为类型	用户人数
点击（Click）	19865
加购（Cart）	1215
收藏（Favorite）	11959
购买（Purchase）	19877

分析发现：用户在“点击 → 加购 → 购买”过程中存在明显流失现象，说明平台仍存在较大转化优化空间。

2. 用户画像分析

项目从：年龄分布、性别分布、不同年龄复购率、不同性别复购率等维度分析用户画像。





实验发现：中青年用户复购率较高，说明该群体是平台核心高价值用户。

十一、预测结果输出

模型对测试集进行预测后，输出用户在对应商家上的复购概率，并生成提交文件：submission_best.csv

输出字段包括：

字段	含义
user_id	用户 ID
merchant_id	商家 ID
prob	用户复购概率

预测结果可用于：

- 精准营销

- 用户分层
- 优惠券定向投放
- 高价值用户识别

十二、项目结论

本项目完整实现了电商用户复购预测的机器学习建模流程，包括：数据清洗、行为分析、特征工程、模型训练、模型优化、效果评估、结果预测

项目结果表明：用户行为特征是影响复购预测的核心因素、行为转化率特征对模型效果提升显著、用户活跃度与商家运营能力对复购影响明显

最终模型 AUC 达到 0.6532，在电商复购预测场景中达到较稳定 baseline 水平，具备一定业务应用价值。

十三、项目收获

通过本项目，进一步掌握了：电商数据分析完整流程、Pandas 数据处理与特征工程、XGBoost 模型训练与调参、AUC 指标与样本不平衡处理、用户增长与精准营销分析思路。同时增强了将机器学习模型应用于真实业务场景的实践能力。